

Ciclo de Vida do Processo de Ciência de Dados


Felipe Kenji Chikuji

Consultor Dados & IA

Agenda

- ✓ Overview do processo de Ciência de Dados


Entender o processo de aprendizado de máquina - Machine Learning



Você é um **ALUNO** do ensino médio e sua lição de casa é:
 Criar uma **FÓRMULA** para converter **Celsius** em **Fahrenheit**.

Dados Coletados ou Histórico

Celsius(x)	Fahrenheit(y)
0	32.00
1	33.80
2	35.60
3	37.40
4	39.20
5	41.00
100	212.00



$$a = \frac{y_M - y_A}{x_M - x_A} \Rightarrow a = \frac{y - y_P}{x - x_P}$$

$$y - y_P = a(x - x_P)$$

$$\Rightarrow y - y_P = ax - ax_P \Rightarrow y = ax + (-ax_P + y_P)$$

$$\Rightarrow y = ax + b$$

✓ Equação reduzida da reta

$$a = (212 - 32) / (100 - 0) = 1,8$$


$$b = 32$$

$$y = ax + b$$



$$^{\circ}\text{F}(y) = 1,8 * ^{\circ}\text{C}(x) + 32$$

Entender o processo de aprendizado de máquina - Machine Learning



Você é um **ALUNO** do ensino médio e sua lição de casa é: Criar uma **FÓRMULA** para converter **Celsius** em **Fahrenheit**.

Celsius(x)	Fahrenheit(y)
0	32.00
1	33.80
2	35.60
3	37.40
4	39.20
5	41.00
100	212.00

(x)	(y)
0	32.00
100	212.00

$$a = (212-32)/(100-0) = 1,8$$
$$b = 32$$
$$y = ax + b$$


$$^{\circ}\text{F}(y) = 1,8 * ^{\circ}\text{C}(x) + 32$$



(x)	(y)	y'
0	32.00	32.00
1	33.80	33.80
2	35.60	35.60
3	37.40	37.40
4	39.20	39.20
5	41.00	41.00
100	212.00	212.00

Identificar tarefas de aprendizado de máquina


- Classificação
- Regressão
- Previsão de série temporal
- Pesquisa Visual Computacional
- NLP (processamento de linguagem natural)



1




2



3



4



5

Identificar a fonte de dados e o formato

1. Identifique a **fonte de dados**.
2. Identifique o **formato de dados atual**.
3. Identifique o **formato de dados desejado**.

1

```
{ "deviceId": 43819, "machine": "Machine2", "time"="2021-07-14T12:47:33Z", "temperature": 23 }  
{ "deviceId": 38273, "machine": "Machine1", "time"="2021-07-14T12:47:54Z", "temperature": 20.4 }  
{ "deviceId": 29482, "machine": "Machine1", "time"="2021-07-14T12:48:35Z", "temperature": 20.6 }  
{ "deviceId": 58291, "machine": "Machine2", "time"="2021-07-14T12:48:36Z", "temperature": 23 }
```



2

Device ID	Machine	Date	Time	Temperature
29482	Machine1	2021-07-14	12:47:39	20.4
38273	Machine1	2021-07-14	12:47:49	20.6
43819	Machine2	2021-07-14	12:47:33	23
38273	Machine1	2021-07-14	12:47:54	20.6
58291	Machine2	2021-07-14	12:48:36	23



3

Machine	Date	Time	Temperature
Machine1	2021-07-14	12:47	20.5
Machine2	2021-07-14	12:47	23
Machine1	2021-07-14	12:48	20.5

Escolha como fornecer dados para fluxos de trabalho de aprendizado de máquina

Separar a computação do armazenamento:

Um dos benefícios da nuvem é a capacidade de escalar ou reduzir verticalmente a computação de acordo com suas demandas.

Além disso, você pode encerrar a computação quando não precisar dela e reiniciá-la quando quiser usá-la novamente.

Armazenar dados para cargas de trabalho de treinamento de modelo:

Quando você usa o Azure Machine Learning, o Azure Databricks ou o Azure Synapse Analytics para treinamento de modelo, há três opções comuns para armazenar dados:

- Armazenamento do Blobs do Azure
- Azure Data Lake Storage (Gen 2)
- Banco de Dados SQL do Azure

Criar uma solução de ingestão de dados


Crie um pipeline de ingestão de dados:

- Use o Azure Synapse Analytics, o Azure Databricks ou o Azure Machine Learning.


Crie uma solução de assimilação de dados:

Uma abordagem comum para uma solução de ingestão de dados é:

1. Extraia dados brutos de sua fonte (como um sistema de CRM ou dispositivo IoT).
2. Copie e transforme os dados com o Azure Synapse Analytics.
3. Armazene os dados preparados em um Armazenamento de Blobs do Azure.
4. Treine o modelo com o Azure Machine Learning.



Escolher um serviço para treinar um modelo de machine learning



Serviços de IA do Azure

Personalizar ou consumir modelos predefinidos.

Economizar tempo e esforço.



Microsoft Fabric

One platform for all data engineering and data science projects at scale.

Offers an easy-to-use UI, notebooks, and scripts.



Azure Databricks

Use notebooks para engenharia de dados e ciência de dados em escala.

Oferece computação distribuída (PySpark).



Azure Machine Learning

Gerenciar modelos de aprendizado de máquina desde o desenvolvimento, passando pelo teste e chegando à produção.

Usar Python em notebooks e scripts.

Decidir entre opções de computação



CPU ou GPU

Para conjuntos de dados tabulares menores, a CPU será suficiente e mais barata de usar

Sempre que trabalhar com dados não estruturados, como imagens ou texto, as GPUs serão mais eficientes e eficazes.



Uso geral ou otimizado para memória

Uso geral: tem uma taxa de CPU/memória equilibrada. Ideal para teste e desenvolvimento com conjuntos de dados menores.

Otimizado para memória: tem uma alta taxa de memória para CPU.

Ótima opção para análise na memória.



Spark

Serviços como o Azure Synapse Analytics e o Azure Databricks oferecem computação do Spark.



Um cluster do Spark consiste em um nó de driver e nós de trabalho.



Monitorar a utilização da computação

Configurar seus recursos de computação para treinar o aprendizado de máquina de um modelo é um processo iterativo.

Entender como o modelo será consumido



Implantar um modelo em um ponto de extremidade

Ao treinar um modelo, a meta geralmente é integrar o modelo a um aplicativo.

Para facilitar a integração de um modelo a um aplicativo, você pode usar pontos de extremidade.


Decidir sobre implantação em tempo real ou em lote

Ao implantar um modelo, você tem duas opções:

Obter previsões em tempo real:


Se você quiser que o modelo pontue os novos dados conforme forem fornecidos, você precisará de previsões em tempo real.

Previsões em tempo real geralmente são necessárias quando um modelo é usado por um aplicativo, como um aplicativo móvel ou um site.




Obter previsões em lote:

Se você quiser que o modelo marque novos dados em lotes e salve os resultados como um arquivo ou em um banco de dados, precisará das previsões em lote.



Explorar uma arquitetura de MLOps

1. Instalação: criar todos os recursos do Azure necessários para a solução.
2. Desenvolvimento de modelo (loop interno): explorar e processar os dados para treinar e avaliar o modelo.
3. Integração contínua: empacotar e registrar o modelo.
4. Implantação de modelo (loop externo): implantar o modelo.
5. Implantação contínua: testar o modelo e promovê-lo ao ambiente de produção.
6. Monitoramento: monitorar o desempenho do modelo e do ponto de extremidade.



Ciclo de Vida do Processo de Ciência de Dados

Obrigado e bons estudos!