

Otimizar o treinamento de modelo no Azure Machine Learning

Felipe Kenji Chikuji

Consultor Dados & IA

Agenda

- ✓ Executar um script de treinamento como um trabalho de comando no Azure Machine Learning
- ✓ Monitoramento do Treinamento de Modelos com Mlflow
- ✓ Realização de Ajuste de Hiperparâmetros com o Azure ML
- ✓ Execução de Pipelines no Azure Machine Learning

Executar um script de treinamento como um trabalho de comando no Azure Machine Learning

Converter um notebook em um script


- Os notebooks são ideais para exploração e desenvolvimento.
- Os scripts são ideais para testes e automação no ambiente de produção.



Para criar um script pronto para produção, o seguinte é necessário:

1. Remover códigos não essenciais.
2. Refatorar o código em funções.
3. Testar o script (no terminal).

Configurar um trabalho de comando



- Quando você tem um **script** que deseja executar, você pode executá-lo como um trabalho de **comando**.
- Configure o trabalho de comando especificando os parâmetros de trabalho necessários e envie o trabalho para o workspace do Azure Machine Learning para executar o script.

Usar parâmetros em um trabalho de comando

Para executar um script com entradas diferentes, use os **parâmetros**:

- Importe a biblioteca **argparse** no script.
- Use o método `ArgumentParser()` para definir argumentos para parâmetros.
- Especifique os parâmetros no script, inclua nome, tipo e valor padrão.
- Ao executar o script, especifique o valor para os parâmetros definidos que você deseja que o script use para essa execução específica.

```
python train.py --training_data diabetes.csv --reg_rate 0.01"
```

Monitoramento do Treinamento de Modelos com MLflow

Acompanhar métricas com o MLflow



O MLflow é uma plataforma de código aberto que foi projetada para gerenciar o ciclo de vida completo do aprendizado de máquina.

Há duas opções para acompanhar os trabalhos de aprendizado de máquina com o MLflow:

- Habilitar o log automático usando **mlflow.autolog()**
- Usar funções de log para acompanhar métricas personalizadas usando **mlflow.log_***

Inclua o **mlflow** e **azureml-mlflow** no ambiente para garantir que os pacotes pip sejam instalados na computação antes de executar o script.

Habilitar o autoregistro



Ao trabalhar com uma das bibliotecas comuns para aprendizado de máquina, você pode habilitar o **registro em log automático** no MLflow.

O registro em log automático registra **parâmetros, métricas** e **artefatos** de modelos sem que seja necessário especificar o que precisa ser registrado.

Python

```
import mlflow  
  
mlflow.autolog()
```



Registrar métricas personalizadas com o MLflow

Dependendo do tipo de valor que você deseja registrar, use o método relevante do MLflow para armazenar o parâmetro, a métrica ou o artefato com a execução experimental:

- **mlflow.log_param():** registrar parâmetro de chave-valor único. Use essa função para um parâmetro de entrada que você deseja registrar.
- **mlflow.log_metric():** registrar métrica de chave-valor única. O valor deve ser um número. Use essa função para qualquer saída que você queira armazenar com a execução.
- **mlflow.log_artifact():** registrar um arquivo. Use essa função para qualquer gráfico que você queira registrar, e salve como arquivo de imagem primeiro.

Exibir as métricas no Estúdio do Azure Machine Learning

- As métricas registradas serão exibidas nas guias **Visão geral** e **Métricas**.
- Os gráficos registrados como artefatos são exibidos em **Imagens**.
- Encontre outros artefatos, como arquivos de modelo, em **Saídas + logs**.



Recuperar métricas com o Mlflow em um notebook



Use o MLflow em um notebook conectado ao workspace do Azure Machine Learning para ter mais controle sobre quais execuções você deseja recuperar para comparar.

Listar experimentos:

```
experiments =  
mlflow.search_experiments(max_results=2)  
for exp in experiments:  
    print(exp.name)
```


Recuperar execuções:

```
mlflow.search_runs(exp.experiment_id)
```

Realização de Ajuste de Hiperparâmetros com o Azure Machine Learning

Entender o ajuste de hiperparâmetros

O **ajuste de hiperparâmetro** é realizado por meio do treinamento de vários modelos, usando o mesmo algoritmo e os mesmos dados de treinamento, mas valores de hiperparâmetro diferentes.



Usar um trabalho de varredura para ajuste de hiperparâmetro

No Azure Machine Learning, você pode ajustar os hiperparâmetros executando um trabalho de varredura.

- 1 Criar um script de treinamento para ajuste de hiperparâmetro
- 2 Configurar e executar um trabalho de varredura
- 3 Monitorar e revisar trabalhos de varredura (filho)

Definir espaço de pesquisa



O conjunto de valores de hiperparâmetro testado durante o ajuste de hiperparâmetro é conhecido como o **espaço de pesquisa**. A definição do intervalo de possíveis valores que podem ser escolhidos depende do tipo de hiperparâmetro.

- 1 Hiperparâmetros discretos:** alguns hiperparâmetros exigem valores discretos – em outras palavras, você deve selecionar o valor em um determinado conjunto *finito* de possibilidades.
- 2 Hiperparâmetros contínuos:** alguns hiperparâmetros são *contínuos* – em outras palavras, você pode usar qualquer valor ao longo de uma escala, resultando em um número *infinito* de possibilidades

Definir um espaço de pesquisa: para definir um espaço de pesquisa para ajuste de hiperparâmetro, crie um dicionário com a expressão de parâmetro apropriada para cada hiperparâmetro nomeado

Configurar um método de amostragem

Os valores específicos usados em uma execução de ajuste de hiperparâmetro, ou trabalho de varredura, dependem do tipo de amostragem usada. Há três métodos de amostragem principais disponíveis no Azure Machine Learning:

- 1 Amostragem de grade:** tenta todas as combinações possíveis
- 2 Amostragem aleatória:** escolhe valores aleatoriamente no espaço de pesquisa
 - **Sobol:** adiciona uma semente à amostragem aleatória para tornar os resultados reproduzíveis
- 3 Amostragem bayesiana:** escolhe novos valores com base nos resultados anteriores

Configurar término antecipado

- Ao configurar um trabalho de varredura no Azure Machine Learning, você pode definir um número máximo de avaliações.
- Uma abordagem mais sofisticada pode ser parar um trabalho de varredura quando modelos mais recentes não produzem resultados significativamente melhores.
- Para interromper um trabalho de varredura com base no desempenho dos modelos, você pode usar uma **política de encerramento antecipado**.

Configurar término antecipado

Quando usar uma política de encerramento antecipado

Se você deve ou não usar uma política de encerramento antecipado depende do espaço de pesquisa e do método de amostragem com o qual você está trabalhando.

Uma **política de encerramento antecipado** pode ser especialmente benéfica ao trabalhar com hiperparâmetros contínuos em seu espaço de pesquisa.

Política de encerramento antecipado



Há dois parâmetros principais quando você opta por usar uma política de encerramento antecipado:

evaluation_interval:

especifica em qual intervalo você deseja que a política seja avaliada

delay_evaluation:

especifica quando começar a avaliar a política

Os novos modelos podem continuar a ter um desempenho um pouco melhor que os modelos anteriores. Para determinar a extensão segundo a qual um modelo deve ter um desempenho melhor que o apresentado em avaliações anteriores, há três opções de encerramento antecipado:

- **Política Bandit**
- **Política de Encerramento Mediana**
- **Política de seleção de truncamento**



Política Bandit



Você pode usar uma política do Bandit para interromper uma avaliação se, até o momento, a métrica de desempenho de destino não superar a melhor avaliação por uma margem especificada.

Python

```
from azure.ai.ml.sweep import  
BanditPolicy  
  
sweep_job.early_termination =  
BanditPolicy(  
    slack_amount = 0.2,  
    delay_evaluation = 5,  
    evaluation_interval = 1  
)
```





Política de Encerramento Mediana



Uma política de encerramento mediana abandona as avaliações em que a métrica de desempenho de destino é pior do que a mediana das médias em execução para todas as avaliações.

Python

```
from azure.ai.ml.sweep import  
MedianStoppingPolicy  
  
sweep_job.early_termination =  
MedianStoppingPolicy(  
    delay_evaluation = 5,  
    evaluation_interval = 1  
)
```





Política de seleção de truncamento

Uma política de seleção de truncamento cancela X% das avaliações com pior desempenho em cada intervalo de avaliação com base no valor de *truncation_percentage* especificado para X.

Python

```
from azure.ai.ml.sweep import  
TruncationSelectionPolicy  
  
sweep_job.early_termination =  
TruncationSelectionPolicy(  
    evaluation_interval=1,  
    truncation_percentage=20,  
    delay_evaluation=4  
)
```



Execução de Pipelines no Azure Machine Learning

Criar componentes



Os **componentes** permitem que você crie scripts reutilizáveis que podem ser facilmente compartilhados entre usuários no mesmo workspace do Azure Machine Learning. Você também pode usar componentes para criar um pipeline do Azure Machine Learning.

Estúdio do Machine Learning

mlw-dp100-l2d9c54e3866045448c > Componentes

Componentes

Os componentes são blocos de construção básicos para executar uma tarefa específica (por exemplo, processamento de dados, treinamento de modelo, pontuação, etc.) com portas de entrada/saída predefinidas, parâmetros e ambiente que podem ser reutilizados em diferentes pipelines.

+ Novo Componente Atualizar Arquivar Opções de exibição Incluir arquivado

Pesquisar

Filtrar Colunas

Nome de exibição	Nome	Versão padrão	Tipo	Origem
uci_heart_classifier_scorer	uci_heart_classifier_scorer	1	pipeline	Esse es
Score	my_score	0	command	Esse es
Eval	my_eval	0	command	Esse es
Train_upper_case	my_train	0	command	Esse es

< Anterior Próximo > 25/Página

Usar um componente:

- Para criar um pipeline
- Para compartilhar o código pronto para uso

Criar um componente



Um componente consiste em três partes:

Metadados

Inclui o nome do componente, a versão, entre outros.

Interface

Inclui os parâmetros de entrada esperados (como um conjunto de dados ou hiperparâmetro) e a saída esperada (como métricas e artefatos)

Comando, código e ambiente

Especifica como executar o código

Criar um componente



Para criar um componente, você precisa de dois arquivos:

- Um script que contém o fluxo de trabalho que você deseja executar
- Um arquivo YAML para definir os metadados, a interface e o comando, o código e o ambiente do componente

Registrar um componente



- Para usar componentes em um pipeline, você precisará do script e do arquivo YAML.
- Para tornar os componentes acessíveis a outros usuários no workspace, você também poderá registrar componentes no workspace do Azure Machine Learning.

Você pode registrar um componente com o seguinte código:


Python

```
prep = ml_client.components.create_or_update(prepare_data_component)
```

Criar um pipeline

No Azure Machine Learning, um pipeline é um fluxo de trabalho de tarefas de machine learning em que cada tarefa é definida como um componente.

- Um pipeline do Azure Machine Learning é definido em um arquivo YAML. O arquivo YAML inclui o nome do trabalho de pipeline, entradas, saídas e configurações.



Executar um trabalho de pipeline



- Quando você cria um pipeline baseado em componentes no Azure Machine Learning, pode executar o fluxo de trabalho como um **trabalho de pipeline**.

Executar um trabalho de pipeline

Configurar um trabalho de pipeline

Um pipeline é definido em um arquivo YAML, que você também pode criar usando a função `@pipeline()`

Executar um trabalho de pipeline

Quando tiver configurado o pipeline, estará tudo pronto para executar o fluxo de trabalho como um trabalho de pipeline

Agendar um trabalho de pipeline

Para agendar um trabalho de pipeline, você usará a classe `JobSchedule` para associar uma agenda a um trabalho de pipeline

Recapitulação



Nesta seção, abordamos:

Converter seus notebooks em scripts.

Executar um script como um trabalho de comando no Azure ML.

Acompanhar modelos de aprendizado de máquina treinados em trabalhos de comando com o MLflow.

Treinar vários modelos com ajuste de hiperparâmetro e um trabalho de varredura.

Como criar e registrar componentes para reutilizar código no Azure ML.

Como criar e executar pipelines no Azure ML.

Otimizar o treinamento de modelo no Azure Machine Learning

Obrigado e bons estudos!