

Gerencie e avalie modelos no Azure Machine Learning

Felipe Kenji Chikuji

Consultor Dados & IA

Agenda

- ✓ Registro de Modelos do MLflow no Azure Machine Learning
- ✓ Criação e Análise de Painéis de IA Responsável no Azure Machine Learning


Registro de Modelos do MLflow no Azure Machine Learning

Registrar um modelo com o MLflow



O MLflow permite registrar um modelo como um **artefato** ou como um **modelo**.

- Quando você registra um modelo como um artefato, ele é tratado como um arquivo.
- Ao registrar um modelo como modelo, você está adicionando informações ao modelo registrado que permite usar o modelo diretamente em pipelines ou implantações.



Registrar um modelo com o MLflow



Quando você registra como um modelo, um arquivo MLmodel é criado no diretório de saída. O arquivo MLmodel contém metadados do modelo, o que permite a rastreabilidade do modelo.

Entenda o formato de arquivo MLmodel



O arquivo MLmodel pode incluir:

- **artifact_path:** durante o trabalho de treinamento, o modelo é registrado nesse caminho.
- **flavor:** a biblioteca de machine learning com a qual o modelo foi criado.
- **model_uuid:** o identificador exclusivo do modelo registrado.
- **run_id:** o identificador exclusivo da execução de trabalho durante a qual o modelo foi criado.

Entenda o formato de arquivo MLmodel



O arquivo MLmodel pode incluir:

- **signature:** especifica o esquema das entradas e saídas do modelo.
- **inputs:** entrada válida para o modelo. Por exemplo, um subconjunto do conjunto de dados de treinamento.
- **outputs:** saída válida do modelo. Por exemplo, previsões de modelo para o conjunto de dados de entrada.

Criação e Análise de Painéis de IA Responsável no Azure Machine Learning

Entenda a IA (inteligência artificial) responsável



A Inteligência Artificial Responsável (IA responsável) é uma abordagem para desenvolver, avaliar e implantar sistemas de IA de maneira segura, confiável e ética.



Confiabilidade e segurança: entenda seus conjuntos de dados

Use a análise de dados para ajudar você a identificar problemas de excesso e falta de representação e ver como os dados são clusterizados no conjunto de dados.

Use a análise de dados quando precisar:

- Explorar as estatísticas do conjunto de dados selecionando filtros diferentes para dividir seus dados em dimensões diferentes (também conhecidas como coortes).
- Entender a distribuição do conjunto de dados em diferentes coortes e grupos de recursos.

Confiabilidade e segurança: entenda seus conjuntos de dados

Use a análise de dados para ajudar você a identificar problemas de excesso e falta de representação e ver como os dados são clusterizados no conjunto de dados.

Use a análise de dados quando precisar:

- Determinar se as suas descobertas relacionadas à imparcialidade, análise de erro e causalidade (derivadas de outros componentes do dashboard) são resultado da distribuição do conjunto de dados.
- Decidir em quais áreas coletar mais dados para atenuar erros decorrentes de problemas de representação, ruído de rótulo, ruído de recurso, desvio de rótulo e fatores semelhantes.

Confiabilidade e segurança: avaliar erros em seu modelo

Identificar coortes errôneas de dados. Explorar se o seu modelo tem um desempenho inferior para grupos demográficos específicos.


- Árvore de erros: particiona os dados em subgrupos interpretáveis.
- Mapa de calor de erros: fatia os dados com base em uma grade unidimensional ou bidimensional de recursos de entrada.

Transparência: interprete seu modelo




Importância do recurso agregada

- Importância do recurso geral para todos os dados de teste
- Indica a influência relativa de cada recurso no rótulo previsto



Importância do recurso individual

- Importância do recurso para uma previsão individual
- Na classificação, isso mostra o suporte relativo para cada classe possível por recurso



Imparcialidade: mitigar a disparidade

A visão geral do modelo e a avaliação de imparcialidade avaliam o desempenho do seu modelo e avaliam os problemas de imparcialidade do grupo do seu modelo.

- **Imparcialidade no desempenho do modelo:** diferentes coortes dos dados têm um desempenho diferente ao comparar métricas de desempenho selecionadas?
- **Imparcialidade na taxa de seleção:** existem coortes dos dados que mais frequentemente obtêm uma previsão favorável?

Criar um painel de IA Responsável



Para criar um painel de IA responsável (RAI), você precisa criar um **pipeline** utilizando os componentes internos. O pipeline deve:

- 1 Comece com o Construtor de painel do RAI Insights.
- 2 Inclua um dos **componentes da ferramenta RAI**.
- 3 Termine com o painel Coletar RAI Insights para coletar todos os insights em um único painel.
- 4 *Opcionalmente*, você também pode adicionar o cartão de pontuação Coletar RAI Insights no final do seu pipeline.

Recapitulação



Nesta seção, abordamos:

Como registrar e documentar modelos com o MLflow no workspace do Azure Machine Learning.

Como criar e explorar o painel da IA responsável.

Gerencie e avalie modelos no Azure Machine Learning

Obrigado e bons estudos!