

Implantar e consumir modelos com o Azure Machine Learning

Felipe Kenji Chikuji

Consultor Dados & IA

Agenda


- ✓ Implantar um modelo em um ponto de extremidade online gerenciado
- ✓ Implantar um modelo em um ponto de extremidade em lote

Implantar um
modelo em um
ponto de
extremidade
online gerenciado

Explorar pontos de extremidade online gerenciados

Um **ponto de extremidade** é um ponto de extremidade HTTPS para o qual você pode enviar dados e que enviará uma resposta (quase) imediata.

Os pontos de extremidade online são usados para gerar previsões em tempo real para pontos de dados individuais.



Implantar um modelo em um ponto de extremidade online gerenciado



Ao implantar um modelo em um ponto de extremidade gerenciado, você tem duas opções:

Implantar um modelo de MLflow:

1. Registre um modelo MLflow com um arquivo `MLModel`.
2. Crie a implantação.
3. Implante um modelo para o ponto de extremidade.

Implante um modelo (personalizado):


1. Registre um modelo com os arquivos de modelo necessários (sujeito ao tipo de modelo).
2. Crie o script de pontuação.
3. Defina um ambiente de execução.
4. Crie a implantação.
5. Implante um modelo para o ponto de extremidade.

Testar pontos de extremidade online gerenciados



Use o Estúdio do Azure Machine Learning para:

- Liste todos os pontos de extremidade.
- Exibir os detalhes e os logs de implantação de um ponto de extremidade.
- Testar o ponto de extremidade.



Implantar um
modelo em um
ponto de
extremidade em
lote

Entender os pontos de extremidade em lote

- 1 Para obter previsões em lote, você poderá implantar um modelo em um ponto de extremidade
- 2 Um **ponto de extremidade** é um ponto de extremidade HTTPS que você pode chamar para disparar um trabalho de pontuação em lote

Entender os pontos de extremidade em lote

- 3 A vantagem desse ponto de extremidade é que você pode disparar o trabalho de pontuação em lote de outro serviço, como o Azure Synapse Analytics ou o Azure Databricks
- 4 Sempre que o ponto de extremidade é invocado, um trabalho de pontuação em lote é enviado para o workspace do Azure Machine Learning

Criar um ponto de extremidade em lote



Para implantar um modelo, primeiro você precisará criar o ponto de extremidade em lote. Para criar um ponto de extremidade em lote, você usará a classe `BatchEndpoint`. Os nomes de ponto de extremidade em lote devem ser exclusivos dentro de uma região do Azure.

Python


```
# create a batch endpoint
endpoint = BatchEndpoint(
    name="endpoint-example",
    description="A batch endpoint",
)
ml_client.batch_endpoints.begin_create_or_update(endpoint)
```

Implantar um modelo em um ponto de extremidade em lote



Você pode implantar vários modelos em um ponto de extremidade em lote.

Sempre que você chamar o ponto de extremidade em lote, que dispara um trabalho de pontuação em lote, a **implantação padrão** será usada, a menos que especificado o contrário.



Executar pontos de extremidade em lote

Usar clusters de computação para implantações em lote

Para processar os novos dados em lotes paralelos, será necessário provisionar um cluster de cálculo com mais de uma instância máxima.

Para criar um cluster de computação, você poderá usar a classe AMLCompute.

Python

```
from azure.ai.ml.entities import AmlCompute

cpu_cluster = AmlCompute(
    name="aml-cluster",
    type="amlcompute",
    size="STANDARD_DS11_V2",
    min_instances=0,
    max_instances=4,
    idle_time_before_scale_down=120,
    tier="Dedicated",
)

cpu_cluster =
ml_client.compute.begin_create_or_update(cpu_cluster)
```

Implantar seu modelo do MLflow em um ponto de extremidade em lote

Implantar um modelo do MLflow em um ponto de extremidade

- Para implantar um modelo do MLflow em um ponto de extremidade em lote, você usará a classe **BatchDeployment**.
- Quando você implanta um modelo, precisa especificar o comportamento do trabalho de pontuação em lote.
- Ao configurar a implantação do modelo, você poderá especificar:
 - `instance_count`
 - `max_concurrency_per_instance`
 - `mini_batch_size`
 - `output_action`
 - `output_file_name`

Implantar um modelo personalizado em um ponto de extremidade em lote

Se você quiser implantar um modelo em um ponto de extremidade em lote sem usar o formato de modelo do MLflow, precisará criar o script de pontuação e o ambiente.

- 1 Criar o script de pontuação:** o script de pontuação é um arquivo que lê os novos dados, carrega o modelo e executa a pontuação.
- 2 Criar um ambiente:** sua implantação requer um ambiente de execução no qual executar o script de pontuação. Qualquer dependência necessária pelo código deve ser incluída no ambiente.
- 3 Configurar e criar a implantação:** finalmente, você pode configurar e criar a implantação com a classe BatchDeployment.

Invocar pontos de extremidade em lote

- Para preparar dados para previsões em lote, você poderá registrar uma pasta como um ativo de dados no workspace do Azure Machine Learning.
- Você poderá usar o ativo de dados registrado como entrada ao invocar o ponto de extremidade em lote com o SDK do Python.


Python

```
from azure.ai.ml import Input

from azure.ai.ml.constants import AssetTypes

input = Input(type=AssetTypes.URI_FOLDER,
              path="azureml:new-data:1")

job = ml_client.batch_endpoints.invoke(
    endpoint_name=endpoint.name,
    input=input)
```



Nome de execução	Status	Criado em	Hora de início	Duração	Criado por	Marcações
phurky_train_vstqsktp0	Em execução	29 de dez de 2023 às 17:08	29 de dez de 2023 às 17:08	2min 16s	SergioMeli-Gawand	inputType : input_data : output...
icp_cashlon_mouqkbb7	Em execução	29 de dez de 2023 às 17:05	29 de dez de 2023 às 17:05	5min 19s	SergioMeli-Gawand	inputType : input_data : output...
gmod_cumini_6nc20k48	Em execução	29 de dez de 2023 às 17:03	29 de dez de 2023 às 17:03	7min 2s	SergioMeli-Gawand	inputType : input_data : output...

Resolver um problema de um trabalho de pontuação em lote

O trabalho de pontuação em lote é executado como um trabalho de pipeline. Se você quiser solucionar problemas do trabalho de pipeline, poderá examinar seus detalhes e as saídas e logs do próprio trabalho de pipeline.

The screenshot displays the Azure Machine Learning workspace interface. On the left, a pipeline diagram for 'uci_heart_classifier_scorer' is shown, which is marked as 'Concluído' (Completed). The pipeline includes steps for data preparation, model training, and scoring. On the right, the 'Visão geral do trabalho de pipeline' (Pipeline Job Overview) panel is visible. It shows a table of pipeline jobs with columns for 'Nome de exibição' (Display Name), 'Status', and 'Criado em' (Created). The 'Trabalhos filho' (Child Jobs) tab is selected, showing two jobs: 'prepared_data' and 'scored_data', both with a status of 'Concluído'.

Nome de exibição	Status	Criado em
prepared_data	Concluído	29 de dez de 2023 à...
scored_data	Concluído	29 de dez de 2023 à...

Recapitulação



Nesta seção, abordamos:

Saiba como implantar um modelo em um ponto de extremidade online gerenciado para previsões em tempo real.

Como implantar um modelo em um ponto de extremidade em lote para previsões em lote.

Implantar e consumir modelos com o Azure Machine Learning

Obrigado e bons estudos!