

Otimizar modelos de linguagem para aplicações generativas de IA

Felipe Kenji Chikuji




Consultor Dados & IA

Agenda

- ✓ Explore e implante modelos do catálogo de modelos
- ✓ Otimize o desempenho do modelo por meio da engenharia prompt
- ✓ Otimize por meio da Retrieval Augmented Generation (RAG)
- ✓ Otimize através do ajuste fino


Introdução ao Azure AI Foundry

Introdução ao Azure AI Foundry



Configure o Azure AI Foundry

- Gerencie com **hubs**
- Crie aplicativos em um **projeto**
- Configure **conexões**



Construa e personalize



- ✓ Selecione um modelo
- ✓ Adicione seus dados
- ✓ Orquestre fluxos de trabalho

The screenshot displays the Azure AI Foundry interface for a project named 'demo-project-1'. The main workspace shows a flow named 'standard-flow-1' with a Python code editor and a graph view.

Code Editor:

```
1 from promptflow import tool
2
3 @tool
4 def echo(input: str) -> str:
5     return input
6
```

Inputs Table:

Name	Type	Value
input	string	`\${joke.output}`


Graph View:

```
graph TD
    inputs --> joke[joke]
    joke --> echo[echo]
    echo --> outputs
```

The interface includes a sidebar with navigation options like Overview, Model catalog, Playgrounds, AI Services, Build and customize, Code, Fine-tuning, Prompt flow, Assess and improve, Tracing, Evaluation, Safety + security, My assets, Models + endpoints, Data + indexes, Web apps, and Management center. The top bar shows the project name and a 'Start compute session' button.

Implemente um modelo

- ✓ Selecione o tipo de implantação
- ✓ Personalize o limite de taxa de tokens por minuto
- ✓ Considere a disponibilidade regional



Explore e implante
modelos do catálogo de
modelos

Selecione um modelo usando uma abordagem estruturada



Como a IA pode resolver o meu caso?

- Defina casos de uso
- Selecione um modelo
- Estabeleça a viabilidade
- Construa um protótipo



Como seleciono o modelo “certo” para meu caso de uso?

- Selecione um modelo
- Engenharia de prompt
- Retrieval Augmented Generation
- Afinação



Posso escalar para cargas de trabalho do mundo real?

- Filtragem de conteúdo
- Segurança e privacidade de dados
- Compensações de capacidade e custos
- Monitoramento

Crie um protótipo para resolver o caso de uso

LLMs vs SLMs

Large Language Models:

- GPT-4
- Mistral Large
- Llama3 70b
- Llama 405B
- Command R, R+

Small Language Models:

- Phi3
- Mistral OSS models
- Llama3 8b

Modalities, tasks and tools

Multi-modal:

- GPT-4o, Phi3-vision

Image generation:

- Dalle3, Stability AI

Embedding models:

- Ada, Cohere

Function calling & JSON support

Regional and domain specific

- Core42 JAIS Arabic language LLM
- Mistral Large is focused on European languages
- Nixtla TimeGEN-1 - Timeseries forecasting

Open and propriety

Premium models first on Azure:

- OpenAI, Mistral Large, Cohere Command R+

100s of Open models from HuggingFace

Open models from Meta, Databricks, Snowflake, Nvidia

Avalie o desempenho do modelo



Avalie o desempenho do seu modelo em diferentes fases, usando diversas abordagens:

- **Referencias de modelo** - Compare métricas disponíveis publicamente entre modelos e conjuntos de dados
- **Avaliações manuais** - Avalie as respostas do seu modelo
- **Métricas tradicionais de aprendizado de máquina** - Meça a proporção do número de palavras compartilhadas entre as respostas geradas e as respostas verdadeiras
- **Métricas assistidas por IA** - Métricas de risco e segurança; Métricas de qualidade de geração

Entenda os benchmarks do modelo

Os conjuntos de dados estão disponíveis publicamente para calcular benchmarks individuais e comparar modelos.

Alguns benchmarks comumente usados são:

Precisão: Compara o texto gerado pelo modelo com a resposta correta de acordo com o conjunto de dados. O resultado será um se o texto gerado corresponder exatamente à resposta e zero caso contrário.

Fluência: avalia até que ponto o texto gerado adere às regras gramaticais, estruturas sintáticas e uso apropriado do vocabulário, resultando em respostas linguisticamente corretas e com som natural.

Coerência: mede se a saída do modelo flui suavemente, se é lida naturalmente e se se assemelha à linguagem humana


Similaridade GPT: quantifica a semelhança semântica entre uma frase (ou documento) verdadeira e a frase de previsão gerada por um modelo de IA

Otimize a precisão após selecionar um modelo


- Otimize o contexto quando o modelo não tiver conhecimento contextual e você quiser maximizar a precisão da resposta.
- Otimize o modelo quando quiser melhorar o formato, o estilo ou a fala da resposta, maximizando a consistência do comportamento.

Otimização
de contexto
*O que o modelo
precisa saber*

Otimização de modelo
Como o modelo precisa agir



Otimize o desempenho para se preparar para a escala



- Por custo: limites e compensações



- Por métricas: Qualidade e segurança



- Por confiança: curadoria e compatível




- Por tamanho: SLM (borda) e LLM (nuvem)

Otimize o desempenho do modelo por meio da engenharia de prompt

Aplicar engenharia de prompt

Para melhorar a saída do modelo como usuário, você pode aplicar engenharia de prompt:


- Forneça instruções claras
- Formate suas instruções
- Use dicas



Atualizar a mensagem do sistema

Para melhorar o resultado do modelo como desenvolvedor, você pode atualizar a mensagem do sistema:

- Use uma/poucas fotos
- Use cadeia de pensamento
- Adicione contexto



Prompty como um ativo de prompt independente da linguagem

Fácil de começar

Codifique primeiro

Intuitivo para desenvolver

Várias linguagens de programação serão suportadas

Implantação simplificada

Observabilidade por meio de rastreamento

Escolha a estrutura

```
1  ---
2  name: Basic Prompt
3  description: A basic prompt that uses the GPT-3 chat API to answer questions
4  authors:
5    - sethjuarez
6    - jietong
7  model:
8    api: chat
9    configuration:
10     azure_deployment: gpt-35-turbo
11  sample:
12     firstName: Jane
13     lastName: Doe
14     question: What is the meaning of life?
15  ---
16  system:
17    You are an AI assistant who helps people find information.
18    As the assistant, you answer questions briefly, succinctly,
19    and in a personable manner using markdown and even add some
20    personal flair with appropriate emojis.
21
22  # Customer
23    You are helping {{firstName}} {{lastName}} to find answers to their questions.
24    Use their name to address them in your responses.
25
26  user:
27    {{question}}
```

Otimizar através Retrieval Augmented Generation (RAG)

Fundamentando um copiloto com seus próprios dados



Os modelos de linguagem criam respostas coerentes às perguntas, mas em que se baseiam essas respostas?

A **fundamentação** fornece contexto específico ao modelo para fornecer respostas precisas e relevantes.


Fundamentando um copiloto com seus próprios dados



Não fundamentado



Fundamentado




Retrieval Augmented Generation (RAG)



Uma **RAG** reúne dados relevantes para incluir no prompt para que o modelo de linguagem utilize como contexto de fundamentação.

Um **padrão RAG** é um design arquitetural para RAG, incluindo dados relevantes recuperados no prompt:

Retrieval Augmented Generation (RAG)




Retrieval Augmented Generation (RAG)



Os dados são armazenados como embeddings em um **índice de busca baseado em vetores**.

Embeddings permitem uma melhor recuperação de dados para *similaridades semânticas* nos resultados da busca.

Retrieval Augmented Generation (RAG)




Adicione seus dados em um fluxo de prompt

Para fundamentar as respostas do seu modelo de linguagem, adicione sua própria fonte de dados para recuperar o contexto relevante:

1. Adicione seus **dados** a um projeto Azure AI.
2. Indexe seus dados com o **Azure AI Search**.
3. Consulte seus dados indexados em um fluxo de prompt com a ferramenta **Index Lookup**.
4. Referencie o **contexto** recuperado no prompt.
5. Envie o prompt com o contexto para um **LLM**.

A resposta gerada será fundamentada pelo contexto recuperado



Otimizar através de Ajuste Fino (fine-tuning)


Entenda quando ajustar finamente um modelo

O ajuste fino melhorará o modelo quando:

- Você tem um caso de uso específico e claro.
- Você precisa que a saída do modelo esteja em um estilo personalizado específico.
- Você deseja ter um desempenho mais consistente fornecendo mais exemplos de few shots do que podem caber no seu prompt

Otimização de contexto
O que o modelo precisa saber

Otimização de modelo
Como o modelo precisa agir



Prepare seus dados para o Ajuste Fino em um modelo de conclusão de chat



Os dados devem ser formatados como um documento JSON Lines (JSONL). Para ajuste fino em uma tarefa de conclusão de chat, seus dados devem incluir:

Mensagem do sistema: Você é um agente de suporte ao cliente do Xbox, cujo objetivo principal é ajudar os usuários com os problemas que estão enfrentando em seus dispositivos Xbox. Você é amigável e conciso. Você fornece apenas respostas factuais para as perguntas e não fornece respostas que não estão relacionadas ao Xbox.

Mensagem do usuário: "O Xbox é melhor que o PlayStation?"

Resposta do assistente: "Peço desculpas, mas não posso fornecer opiniões pessoais. Meu principal objetivo é ajudá-lo com quaisquer problemas relacionados ao seu dispositivo Xbox. Você tem algum problema relacionado ao Xbox que precise de ajuda?"

Opcionalmente: Adicione um peso (0 ou 1) por par chave-valor para pular o ajuste fino em mensagens específicas do assistente.

Ajustar finamente um modelo

1. Selecione o modelo base
2. Selecione seus dados de treinamento
3. Opcional: Selecione seus dados de validação
4. Configure opções avançadas:

Nome	Descrição
batch_size	Número de exemplos de treinamento usados para treinar uma única passagem para frente e para trás.
learning_rate_multiplier	Taxa de aprendizado original usado para o pré-treinamento multiplicado por este valor.
n_epochs	O número de epochs para treinar o modelo. Uma epoch refere-se a um ciclo completo através do conjunto de dados de treinamento.
seed	A seed controla a produtividade do trabalho

Avalie o desempenho dos seus modelos no Azure AI Foundry

Avaliar o desempenho do modelo

Avalie o desempenho do seu modelo em diferentes fases, utilizando uma variedade de abordagens de avaliação:

Padrões de desempenho do modelo

- Compare métricas publicamente disponíveis entre modelos e conjuntos de dados

Avaliações manuais

- Avalie as respostas do seu modelo

Métricas tradicionais de aprendizagem de máquina

- Meça a proporção do número de palavras compartilhadas entre as respostas geradas e as respostas verdadeiras

Métricas assistidas por IA

- Métricas de segurança e risco
- Métricas de geração de qualidade

Entenda os padrões de desempenho do modelo

Bancos de dados estão disponíveis publicamente para calcular benchmarks individuais e comparar entre modelos. Alguns benchmarks geralmente usados são:

Acurácia:

Compara o texto gerado pelo modelo com a resposta correta de acordo com o conjunto de dados. O resultado é um se o texto gerado corresponder exatamente à resposta, e zero caso contrário.

Coerência:

Mede se a saída do modelo flui suavemente, lê-se de forma natural e se assemelha à linguagem humana.

Fluência:

Avalia o quão bem o texto gerado adere às regras gramaticais, estruturas sintáticas e uso apropriado do vocabulário, resultando em respostas linguisticamente corretas e com som natural.

Similaridade GPT:

Avalia a similaridade semântica entre uma sentença (ou documento) de referência correta e a sentença de previsão gerada por um modelo de IA

Explore avaliações manuais



System message

You are an AI assistant helping users with queries related to outdoor/camping gear and clothing. Use the following pieces of context to answer the questions about outdoor/camping gear and clothing as completely, correctly, and concisely as possible.

If the question is not related to outdoor/camping gear and clothing, just say Sorry, I only can answer question related to outdoor/camping gear and clothing. So how can I help? Don't try to make up an answer.

If the question is related to outdoor/camping gear and clothing but vague ask for clarifying questions.

Do not add documentation reference in the response.

Configurations

Add your data

Model

gpt-35-turbo

Max response

800

Temperature

0.7

Manual evaluation result



Run

Import test data

Export

Metric evaluation

Save results

Columns



Input

Expected response

Output

Which tent is the most waterproof?

The Alpine Explorer Tent has the highest

Run to see the model response



Which camping table holds the most weight?

The Adventure Dining Table has a higher weight

Run to see the model response



Otimize o desempenho para se preparar para a escala

Para avaliar aplicativos de chat que você construiu com fluxo de prompt:

1. Crie um conjunto de dados de teste.
2. Crie uma nova avaliação **automatizada**.
3. Selecione um fluxo ou um conjunto de dados com outputs geradas pelo modelo.
4. Selecione as métricas que você deseja avaliar.
5. Execute o fluxo de avaliação.
6. Revise os resultados.

Recapitulação



Nesta seção, abordamos:

Aprendemos o que é o Azure AI Foundry

Como implantar e explorar os modelos no catalogo de modelos.

Como ajustar com engenharia de prompt.

Como ajusta com a arquitetura RAG.

Como ajustar com o Ajuste Fino.

Otimize modelos de linguagem para aplicações generativas de IA

Obrigado e bons estudos!